

# Prueba de Performance con Postman


Este documento presenta el análisis completo de una prueba de carga realizada sobre el endpoint de **login de usuario existente** utilizando **Postman** como herramienta de testing. El objetivo es evaluar el comportamiento del sistema bajo condiciones de carga progresiva, identificar puntos críticos de rendimiento y determinar el funcionamiento de la API y el servidor.

## Test a probar: Login de usuario existente

El endpoint seleccionado para esta prueba es el de autenticación de usuarios. Un login lento o inestable impacta directamente en la experiencia del usuario. Se configuraron validaciones automáticas en Postman para verificar tres aspectos fundamentales en cada respuesta del servidor.

### Validaciones configuradas

- **Status Code:** Verificación del código de estado HTTP retornado por el servidor en cada respuesta.
- **Response Body:** Validación del cuerpo de la respuesta para confirmar que los datos devueltos son correctos.
- **Response Time:** CHK2 — Validate Response time is less than **800ms** (nota: el título original en Postman dice "200", pero el valor correcto es 800ms).



## Configuración de la prueba de carga en Postman

La prueba se configuró con una duración total de **1 minuto** y una carga máxima de **20 usuarios virtuales (VUs)**. La estrategia de rampa fue progresiva para observar el comportamiento del sistema a medida que aumenta la concurrencia. Este enfoque permite identificar con precisión en qué punto exacto el sistema comienza a degradarse.

**1****2****3**

### Fase 1 — Inicio


**7 usuarios** durante los primeros **15 segundos**. El sistema opera con baja carga y tiempos de respuesta estables.

### Fase 2 — Rampa

Subida gradual de **7 a 20 usuarios** durante **15 segundos**. Se observa cómo crecen los request/segundo.

### Fase 3 — Pico


**20 usuarios sostenidos** durante los últimos **30 segundos**. Aquí se detectan los puntos críticos de error y latencia.



# Análisis detallado de los gráficos y métricas

A continuación se presenta el análisis completo del comportamiento del sistema durante los 60 segundos de prueba, desglosado por cada fase de la rampa de carga. Los gráficos obtenidos desde Postman permiten visualizar con claridad la relación entre el número de usuarios virtuales, los requests por segundo (RPS) y el tiempo de respuesta (latencia).

## Comportamiento general por fase



### Fase 1 — 7 usuarios (0–15 seg)

Con 7 usuarios simultáneos el sistema responde de forma estable. No se registran errores. El tiempo promedio de respuesta es de aproximadamente **600 ms**, muy por debajo del umbral de 800 ms. Los requests por segundo promedian **10 RPS**, lo que indica que cada usuario puede completar su solicitud sin demoras significativas.

### Fase 2 — Rampa de 7 a 20 usuarios (15–30 seg)

Durante la rampa, la cantidad de requests por segundo acompaña el crecimiento de usuarios, aumentando a un promedio de **15 RPS**. El tiempo de respuesta se mantiene relativamente estable, sin incrementos preocupantes. Esta fase demuestra que el sistema puede escalar de forma gradual sin problemas inmediatos.

### Fase 3 — Pico de 20 usuarios (30–60 seg)

Al alcanzar los 20 usuarios sostenidos, se observa un **pico de errores**. Los RPS oscilan entre **16 y 9** (hasta caer al final del test), y el tiempo de respuesta se dispara desde **900 ms hasta 2.000 ms**. Esto indica claramente que el sistema comienza a saturarse y no puede procesar todas las solicitudes dentro del umbral aceptable.

## Puntos críticos identificados

### ⚡ Pico máximo de rendimiento


Con **19 usuarios** y un tiempo de respuesta aún inferior a 1 segundo, se alcanza el pico máximo de **18,5 RPS**, lo que equivale a casi 1 request por usuario por segundo. Este es el punto de mayor eficiencia del sistema antes de comenzar a degradarse.

### ⚠ Umbral de degradación

A partir de los 20 usuarios simultáneos, el sistema supera su capacidad. La latencia crece y los RPS comienzan a caer, lo que indica que el servidor no puede mantener el ritmo de procesamiento bajo esa carga.

## Análisis de errores y fallos

Durante la fase de pico de usuarios se detectaron errores. El análisis de los gráficos revela un patrón claro: los errores aparecen después de valores altos de latencia y promedios RPS se intersecan, lo que sugiere que el servidor se satura y comienza a rechazar o tardar en procesar solicitudes.



5,8%

Pico de error

Porcentaje de requests fallidos en el momento de mayor saturación del sistema, durante el pico de 20 usuarios.

~40%

Fallos totales

Casi el 40% de las peticiones no completaron correctamente según las validaciones configuradas, un indicador crítico de inestabilidad.

0,14%

Error total

Porcentaje de error acumulado en toda la prueba: de 730 requests, solo 1 falló por **timeout** (superó los 800ms de validación).

1,8s

Latencia crítica

Con VU:20, RPS:12 y latencia de casi 1,8 segundos, se produce la tendencia más alta de errores en toda la prueba.

## Comportamiento post-error y recuperación

Al finalizar la prueba, se observa un comportamiento particular: después del pico de errores, el servidor continúa respondiendo pero con una latencia significativamente mayor. Con **VU:20, RPS:2,5** y una latencia que alcanza casi **2,3 segundos**, el sistema muestra 0 errores de respuesta en ese momento, pero la velocidad de procesamiento ha caído drásticamente.



Este patrón indica que luego de una recuperación por error, el servidor sigue respondiendo pero mucho más lento, lo que en un entorno real se traduciría en usuarios esperando aplicación. La caída de RPS de 18,5 a 2,5 representa una reducción del **86% en la capacidad de procesamiento** bajo carga sostenida.

# Conclusión final y recomendaciones

## Conclusión

El endpoint de login **funciona correctamente en condiciones normales**, pero bajo carga con 20 usuarios simultáneos el sistema se vuelve **inestable**: las respuestas se vuelven lentas (hasta 2,3 segundos), casi la mitad de las solicitudes fallan según las validaciones configuradas, y el consumo de memoria alcanza niveles críticos del 93%. Si bien el porcentaje de errores absolutos es bajo (0,14%), el porcentaje de fallos de validación es alarmantemente alto (~40%), lo que indica que el sistema no cumple consistentemente con los requisitos de tiempo de respuesta definidos.

El patrón observado — aumento de latencia, caída de RPS, aparición de errores por timeout y recuperación lenta — es característico de un sistema que ha superado su capacidad de procesamiento y cuyo recurso limitante (en este caso, la memoria) está siendo agotado, siendo esto un problema de **capacidad y escalabilidad**.

## Recomendaciones:

 **Recomendación prioritaria:** El sistema necesita ajustes de rendimiento y escalabilidad **antes** de poder manejar altos volúmenes de usuarios concurrentes de forma confiable en producción. Se recomienda no exponer el endpoint a carga real de 20+ usuarios simultáneos hasta que se resuelvan los problemas de memoria y se validen las mejoras con una nueva ronda de pruebas.